

GOSIM Paris 2026

May 5-6, 2026 Station F, Paris



GOSIM

GOSIM Paris 2026



CONTENTS

GOSIM Paris 2026

Part 01

单击此处修改标题

Part 02

单击此处修改标题

Part 03

单击此处修改标题

Part 04

单击此处修改标题



01









Thanks!



Pretraining + RL

PRETRAINING SETUP

- No prompt: OCR behavior embedded in weights
- Batch 384, LR 1e-4, no weight decay
- Loss on assistant tokens only
- 96 H100s, bf16, FA-2, soup + data aug

RL SETUP


- GRPO for 1 epoch
- AdamW LR 4e-5, KL $\beta = 0.01$, 28 rollouts/prompt with vLLM

WHY RL?

- Heterogeneous annotations: different conventions (^_ vs sup/sub, italics, headings, whitespace, capitalization, etc.)
- SFT blends these conventions, producing inconsistent outputs across pages
- Also plateaus on loops, math rendering errors, formatting drift
- Verifiable rewards target these directly, beyond likelihood

RLVR RECIPE

- Extended OlmOCR-2 recipe (GRPO)
- Adds: zlib repetition penalty, KaTeX math renderability, flip headers/footers



Evaluating document OCR is hard by design

MANY VALID OUTPUTS

- Same equation: x^2 vs $x^{²}$
- Same heading: "# H1" vs "**H1**"
- Tables: Markdown vs HTML
- Whitespace, italics, capitalization

EDIT DISTANCE IS BLIND

- Penalizes correct alternative encodings
- Tables: row/col swap costs more than missing headers
- Favors models that match one convention

STRUCTURAL FAILURES HIDDEN

- Repetition loops, watermark hallucinations
- Can still score well on character metrics
- Aggregate scores stay deceptively high

LLM/VLM-as-judge: closer to semantic correctness, but cost and bias make it impractical.

Pragmatic response: use unit tests instead of edit distance



OlmOCR-Bench: unit tests over edit distance

1,403 human-verified PDF pages · 7,010 unit test cases across 5 categories

5 TEST TYPES

- Text Presence: fuzzy-match a span appears
- Text Absence: verify content is absent (opinionated: penalizes visible text)
- Reading Order: check relative ordering
- Table Accuracy: cells + neighbors (HTML rowspan/colspan)
- Math Formula: KaTeX render, symbol-position match

OUR SETUP


- Keep headers/footers: full-page extraction is the goal
- 3 runs per page, averaged for lower variance
- No pre/post-processing: image in, raw output evaluated

KEY DESIGN CHOICES

- Math: LaTeX render + symbol-position match, not LaTeX strings
- Text: max_edits tolerance on longer strings

Still: no benchmark is perfect. Systematic gaps remain, and results should be read alongside qualitative inspection.

Source: Poznanski et al., olmOCR (arXiv:2502.18443)



ParseBench: a document parsing benchmark for AI agents

Recent benchmark designed for agent-facing parsing: evaluates semantic correctness on enterprise documents through structural rule-based tests.

WHAT'S NEW

- ~2000 human-verified pages from enterprise docs
- 167K+ test rules across 5 dimensions
- Insurance, finance, government sources
- Structural record matching for tables and charts
- released April 2026

5 CAPABILITY DIMENSIONS

- Tables: cells, headers, merged cells, hierarchy
- Charts: exact data-point extraction
- Content faithfulness: omissions, hallucinations, order
- Semantic formatting: styling, titles, LaTeX, code
- Visual grounding: element localization + attribution

STILL OPINIONATED


Enterprise-weighted document mix · rules embed encoding choices, alternatives penalized · English-dominant.

Source: Zhang et al., ParseBench (arXiv:2604.08538)




Pushing the pareto frontier at 1B

OLMOCR-BENCH




PARSEBENCH



Pushes the performance-efficiency frontier at 1B on both benchmarks

Strong: dense text, math, multi-column, tables · Limits: charts, bbox layout(outside training scope)

Other benchmarks: #1 open model on PDF table extraction, behind only Gemini 3 Pro/Flash (arXiv 2603.18652) · leading 1B model on French PDF→Markdown (arXiv 2602.11960)



Document in, structured Markdown out

Ofi Invest Precious Metals R

Reporting Mensuel - Actifs réels - Mars 2024

L'objectif de gestion d'Ofi Invest Precious Metals est d'offrir une exposition synthétique à l'indice de stratégie « Basket Precious Metals Strategy ». Cet indice de stratégie vise à être représentatif d'un panier composé de métaux précieux et de produits sur taux d'intérêt. Le fonds reproduit à la hausse comme à la baisse les variations de l'indice de stratégie. L'équipe de gestion du fonds propose une exposition au secteur des métaux précieux sans passer par les actions minières du secteur, avec une offre simple et transparente. Le fonds est couvert quotidiennement contre le risque de change.


Chiffres clés au 28/03/2024	
Valeur Liquidative Part R (en euros) :	705,90
Actif net de la Part R (en millions d'euros) :	259,87
Actif net Total des Parts (en millions d'euros) :	492,50
Nombre de lignes :	13

Caractéristiques du fonds	
Code ISIN :	FR001170182
Ticker :	PRIMPMR FP
Classification Europerformance :	Matières Premières
Principaux risques :	Risque de contrepartie, risque lié à l'emploi d'ITF
Société de gestion :	OFI INVEST ASSET MANAGEMENT
Analyste/Gérant :	Benjamin LOUVET - Olivier DAGUIN - Marion BALESTIER
Forme juridique :	SICAV
Affectation du résultat :	Capitalisation
Devise :	EUR
Date de création :	08/03/2012
Horizon de placement :	Supérieur à 5 ans
Valorisation :	Quotidienne
Limite de souscription :	J à 12h
Limite de rachat :	J à 12h
Règlement :	J+2
Commission de souscription :	Néant
Commission de rachat :	Néant
Commission de surperformance :	Néant
Frais de gestion et autres frais administratifs et d'exploitation :	1,51%
Dépositaire :	SOCIETE GENERALE PARIS
Valorisateur :	SOCIETE GENERALE PARIS



Performances & Volatilités										
	Depuis création		3 ans glissants		1 an glissant		Année 2024		6 mois	3 mois
	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.	Perf.	Perf.
Ofi Invest Precious Metals R	-29,41%	19,97%	-20,22%	21,42%	-6,14%	20,43%	-0,55%	18,79%	4,12%	-0,55%
Source : Eurperformance										

Performances mensuelles													
	Jan.	Fév.	Mars	Avr.	Mai	Jun	Juillet	Août	Sept.	Oct.	Nov.	Déc.	Année
2019	4,02%	3,39%	-4,41%	0,78%	-3,28%	8,02%	2,33%	6,00%	-2,71%	4,64%	-2,70%	4,89%	22,01%
2020	4,39%	-2,22%	-6,79%	2,33%	7,61%	0,41%	12,93%	3,68%	-5,03%	-2,80%	1,02%	8,43%	24,54%
2021	-2,76%	-0,07%	0,63%	4,94%	2,94%	-6,63%	-1,23%	-3,69%	-9,26%	4,42%	-6,29%	4,98%	-12,54%
2022	3,73%	5,63%	-1,27%	-3,36%	-5,06%	-4,98%	0,90%	-6,01%	1,67%	-2,71%	7,55%	3,56%	-1,46%
2023	-1,17%	-9,11%	7,37%	3,51%	-5,97%	-5,55%	4,56%	-1,75%	-4,55%	1,51%	0,66%	2,46%	-8,98%
2024	-4,84%	-2,67%	7,38%										-0,55%



Document d'information non contractuel. Le présent document ne s'adresse qu'aux porteurs de parts ou actions du présent OPC. Les informations contenues dans ce document ne sauraient avoir une quelconque valeur contractuelle. Seuls le prospectus complet de l'OPC et ses derniers états financiers font foi. Les performances passées ne préjugent en rien des résultats futurs et ne sont pas constantes dans le temps. Les performances présentées incluent l'ensemble des frais hors commission de souscription et rachat. L'investissement dans l'OPC présente des risques liés à la variation de la valeur des parts ou actions de l'OPC dues aux fluctuations du marché, les investissements réalisés pouvant donc varier tant à la hausse qu'à la baisse et les souscripteurs de l'OPC pouvant par conséquent perdre tout ou partie de leur capital initialement investi. Ce document n'a aucun caractère contractuel et ne fournit des informations qu'à titre indicatif. Le souscripteur reconnaît avoir reçu le prospectus communiqué à l'AMF préalablement à son investissement. La société de gestion ne garantit pas que les informations contenues dans ce document sont exactes, complètes et à jour malgré le soin apporté à sa préparation. Aucune responsabilité ne pourra être encourue du fait de pertes subies par les souscripteurs ayant fondé leur décision d'investissement sur ce seul document. Aucune reproduction, partielle ou totale, des informations contenues dans ce document n'est autorisée sans l'accord préalable de son auteur. Pour tout renseignement complémentaire relatif à l'OPC, le souscripteur pourra s'adresser à Ofi Invest Asset Management (22, rue Vernier 75017 Paris).

CONTACT - Département commercial - 01 40 68 17 17 - service.client@ofi-invest.com

Ofi Invest Asset Management - société de gestion de portefeuille S.A. à Conseil d'Administration au capital de 71 957 490 euros - RCS Paris 384 940 342 - APE 6630 Z - Agrément AMF n° GP 92-12 - FR 51384940342

22, rue Vernier 75017 Paris - France - Tél. : +33 (0)1 40 68 17 17 - www.ofi-invest-am.com



1

Ofi Invest Precious Metals R

Reporting Mensuel - Actifs réels - Mars 2024

L'objectif de gestion d'Ofi Invest Precious Metals est d'offrir une exposition synthétique à l'indice de stratégie « Basket Precious Metals Strategy ». Cet indice de stratégie vise à être représentatif d'un panier composé de métaux précieux et de produits sur taux d'intérêt. Le fonds reproduit à la hausse comme à la baisse les variations de l'indice de stratégie. L'équipe de gestion du fonds propose une exposition au secteur des métaux précieux sans passer par les actions minières du secteur, avec une offre simple et transparente. Le fonds est couvert quotidiennement contre le risque de change.

Chiffres clés au 28/03/2024	
Valeur Liquidative Part R (en euros) :	705,90
Actif net de la Part R (en millions d'euros) :	259,87
Actif net Total des Parts (en millions d'euros) :	492,50
Nombre de lignes :	13

Caractéristiques du fonds

Code ISIN :	FR001170182
Ticker :	PRIMPMR FP
Classification Europerformance :	Matières Premières
Principaux risques :	Risque de contrepartie, risque lié à l'emploi d'ITF
Société de gestion :	OFI INVEST ASSET MANAGEMENT
Analyste/Gérant :	Benjamin LOUVET - Olivier DAGUIN - Marion BALESTIER
Forme juridique :	SICAV
Affectation du résultat :	Capitalisation
Devise :	EUR
Date de création :	08/03/2012
Horizon de placement :	Supérieur à 5 ans
Valorisation :	Quotidienne
Limite de souscription :	J à 12h
Limite de rachat :	J à 12h
Règlement :	J+2
Commission de souscription :	Néant
Commission de rachat :	Néant
Commission de surperformance :	Néant
Frais de gestion et autres frais administratifs et d'exploitation :	1,51%
Dépositaire :	SOCIETE GENERALE PARIS
Valorisateur :	SOCIETE GENERALE PARIS

Evolution de la performance sur 5 ans glissants



Profil de risque

Niveau : 1 2 3 4 5 6 7

Performance sur le mois



Performance depuis le début de l'année



Performances & Volatilités

Ofi Invest Precious Metals R	Depuis création		3 ans glissants		1 an glissant		Année 2024		6 mois		3 mois	
	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.	Perf.	Volat.
Ofi Invest Precious Metals R	-20,41%	19,97%	-20,22%	21,42%	-6,14%	20,43%	-0,55%	18,79%	4,12%	-0,55%		

Source : Europerformance

Performances mensuelles

	Jan.	Fév.	Mars	Avr.	Mai	Jun	Juillet	Août	Sept.	Oct.	Nov.	Déc.	Année
2019	4,02%	3,39%	-4,41%	0,78%	-3,28%	8,02%	2,33%	6,00%	-2,71%	4,64%	4,89%	22,01%	
2020	4,39%	-2,22%	-6,79%	2,33%	7,61%	0,41%	12,93%	3,68%	-5,03%	-2,80%	1,02%	8,43%	24,54%
2021	-2,76%	-0,07%	0,63%	4,94%	2,94%	-6,63%	-1,23%	-3,69%	-9,26%	4,42%	-6,29%	4,98%	-12,54%
2022	3,73%	5,63%	-1,27%	-3,36%	-5,06%	-4,98%	0,90%	-6,01%	1,67%	-2,71%	7,55%	3,56%	-1,46%
2023	-1,17%	-9,11%	7,37%	3,51%	-5,97%	-5,55%	4,56%	-1,75%	-4,55%	1,51%	0,66%	2,46%	-8,98%
2024	-4,84%	-2,67%	7,38%										-0,55%

Source : Europerformance

Document d'information non contractuel. Le présent document ne s'adresse qu'aux porteurs de parts ou actions du présent OPC. Les informations contenues dans ce document ne sauraient avoir une quelconque valeur contractuelle. Seuls le prospectus complet de l'OPC et ses derniers états financiers font foi. Les performances passées ne préjugent en rien des résultats futurs et ne sont pas constantes dans le temps. Les performances présentées incluent l'ensemble des frais hors commission de souscription et rachat. L'investissement dans l'OPC présente des risques liés à la variation de la valeur des parts ou actions de l'OPC dues aux fluctuations du marché, les investissements réalisés pouvant donc varier tant à la hausse qu'à la baisse et les souscripteurs de l'OPC pouvant perdre tout ou partie de leur capital initialement investi. Ce document n'a aucun caractère contractuel et ne fournit des informations qu'à titre indicatif. Le souscripteur reconnaît avoir reçu le prospectus communiqué à l'AMF préalablement à son investissement. La société de gestion ne garantit pas que les informations contenues dans ce document sont exactes, complètes et à jour malgré le soin apporté à sa préparation. Aucune responsabilité ne pourra être encourue du fait de pertes subies par les souscripteurs ayant fondé leur décision d'investissement sur ce seul document. Aucune reproduction, partielle ou totale, des informations contenues dans ce document n'est autorisée sans l'accord préalable de son auteur. Pour tout renseignement complémentaire relatif à l'OPC, le souscripteur pourra s'adresser à Ofi Invest Asset Management (22, rue Vernier 75017 Paris).

CONTACT - Département commercial - 01 40 68 17 17 - service.client@ofi-invest.com

Ofi Invest Asset Management - société de gestion de portefeuille S.A. à Conseil d'Administration au capital de 71 957 490 euros - RCS Paris 384 940 342 - APE 6630 Z - Agrément AMF n° GP 92-12 - FR 51384940342
22, rue Vernier 75017 Paris - France - Tél. : +33 (0)1 40 68 17 17 - www.ofi-invest-am.com
@CommoOFI

What we learned building LightOnOCR

1

1B ON THE PARETO FRONTIER

A 1B model matches or beats systems 9x larger across multiple benchmarks

2

END-TO-END BEATS PIPELINES

One trained model replaces layout detection, recognition, and assembly

3

DATA IS THE LEVER

All gains come from data and training, with no architectural change

4

RL FIXES WHAT SFT CAN'T

RLVR cleans up the loops, math errors, and formatting drift that SFT plateaus on


5

EVALUATION IS OPINIONATED

Every benchmark bakes in conventions, so report on more than one

WHAT'S NEXT

Broader language coverage · handwriting · make it even faster



1M+ downloads, used in production

1M+

downloads on Hugging Face

20+

languages supported

5.71 pages/s

throughput on an optimized H100 setup

~493K pages/day on an optimized H100 setup

PAPER

arxiv.org/abs/2601.14251

MODEL

huggingface.co/collections/lightonai/lightonocr-2

BLOG

huggingface.co/blog/lightonai/lightonocr-2

DATASET

huggingface.co/datasets/lightonai/LightOnOCR-mix-0126

BBOX BENCHMARK

huggingface.co/datasets/lightonai/LightOnOCR-bbox-bench

API

api.lighton.ai

Why open: no vendor lock-in, fully fine-tunable, pricing and behavior cannot change overnight (unlike closed APIs: Mistral OCR, Azure Document Intelligence, Google Document AI, ...).



LightOnOCR as a hosted service



shell

```
$ curl -X POST https://api.lighton.ai/api/v3/ocr \
  -H "Authorization: Bearer $LIGHTON_API_KEY" \
  -F "file=@document.pdf" \
  -F "pages=1-10"
```

GET ACCESS



scan to request an API key

Hosted at api.lighton.ai · or self-host: weights on HuggingFace, integrated in vLLM, SGLang, Transformers.



Thank you. Questions?

